

实验3：大模型微调

小组成员&分工信息

姓名	学号	班级	分工
严子涵	D202581370	电信博2501	项目统筹、预训练、SFT训练
汤雅琴	M202573115	电信硕2508	手册的OCR处理、数据清洗、数据集构建与开源
罗畅	M202573189	电信硕2505	LoRA微调与Baseline模型对比、PPT制作
赵甫霖	M202573190	电信硕2508	环境配置、Loss日志分析、实验报告撰写

实验环境

软件/硬件	参数/型号	软件/硬件	参数/型号
操作系统环境	Ubuntu 22.04.4 LTS (Linux)	CUDA Version	12.4
CPU	AMD EPYC 7B12 64-Core Processor 8 核	Python Version	3.11.11
RAM	63GB	PyTorch Version	2.6.0+cu124
显卡/显存	NVIDIA GeForce RTX 3090 24GB	Minimind	2026-04-01 Update

1. 实验要求

1. 复现开源项目MiniMind（<https://github.com/jingyaogong/minimind>）的训练过程，给出训练过程的损失函数下降曲线
2. 模型训练完成之后，对比自己训练的模型和官方提供模型之间的测试效果
3. 选做：利用《华中科技大学研究生手册》对完成的MiniMind模型进行微调，测试微调之后的模型生成效果。

2. 实验步骤

2.1 环境准备

从项目地址<https://github.com/jingyaogong/minimind> git clone项目，并按照指示安装必要的库、下载官方提供的训练好的模型、训练数据（使用Mini数据 `pretrain_t2t_mini.jsonl` 和 `sft_t2t_mini.jsonl`）

2.2 《华中科技大学研究生手册》微调数据准备

手册是典型的冗长、教条式文档，不能直接扔进去训练，需要进行数据清洗与指令对齐，本实验执行从手册到微调指令集的如下步骤：

1. 使用PaddleOCR，将手册内容转为Markdown格式
2. 经过手动检查后，按照章节切分，存入SQLite数据库
3. 针对不同章节，结合关键词匹配，调用三个不同的在线大模型（Kimi-K2.5，Qwen3-Max，DeepSeek-V3.2）生成不同数量的问答形式数据
4. 汇总数据，生成适配微调的ShareGPT格式JSONL数据

2.3 预训练

使用官方准备好的预训练数据 `pretrain_t2t_mini.jsonl`，编写预训练sh脚本 `run_pretrain.sh` 如下

代码块

```
1  #!/bin/bash
2
3  # 基础配置
4  SAVE_DIR="./out"
5  DATA_PATH="/hy-tmp/data/pretrain_t2t_mini.jsonl"
6  SAVE_WEIGHT="minimind_pretrain"
7
8  BATCH_SIZE=128          # 单步 Batch Size
9  GRAD_ACC=4              # 梯度累积，等效总 Batch Size = 512
10 LEARNING_RATE=5e-4
11 MAX_SEQ_LEN=512
12 EPOCHS=3
13
14 # 设备与加速配置
15 DEVICE="cuda:0"
16 DTYPE="bfloat16"
17 NUM_WORKERS=8
18 USE_COMPILE=1
19
20 python train_pretrain.py \
21     --save_dir $SAVE_DIR \
22     --save_weight $SAVE_WEIGHT \
23     --data_path $DATA_PATH \
24     --epochs $EPOCHS \
25     --batch_size $BATCH_SIZE \
26     --accumulation_steps $GRAD_ACC \
27     --learning_rate $LEARNING_RATE \
28     --max_seq_len $MAX_SEQ_LEN \
29     --device $DEVICE \
30     --dtype $DTYPE \
```

```
31 --num_workers $NUM_WORKERS \  
32 --use_compile $USE_COMPILE \  
33 --log_interval 50 \  
34 --save_interval 1000 \  
35 --num_hidden_layers 8
```

赋予执行权限并开始执行

2.4 SFT训练

使用官方准备好的SFT数据 `sft_t2t.jsonl`，编写SFT训练脚本 `run_sft.sh` 如下

代码块

```
1  #!/bin/bash  
2  
3  # 第一次运行: 跑第1个Epoch  
4  python train_full_sft.py \  
5      --save_dir "../out" \  
6      --save_weight "minimind_sft_e1" \  
7      --data_path "/hy-tmp/data/sft_t2t_mini.jsonl" \  
8      --from_weight "minimind_pretrain" \  
9      --epochs 1 \  
10     --batch_size 128 \  
11     --accumulation_steps 4 \  
12     --learning_rate 2e-5 \  
13     --max_seq_len 512 \  
14     --num_hidden_layers 8 \  
15     --use_compile 1 \  
16     --log_interval 100 \  
17     --save_interval 10000  
18  
19  # 第二次运行: 基于e1跑第2个Epoch  
20  python train_full_sft.py \  
21      --save_dir "../out" \  
22      --save_weight "minimind_sft_e2" \  
23      --data_path "/hy-tmp/data/sft_t2t_mini.jsonl" \  
24      --from_weight "minimind_sft_e1" \  
25      --epochs 1 \  
26      --batch_size 128 \  
27      --accumulation_steps 4 \  
28      --learning_rate 1e-5 \  
29      --max_seq_len 512 \  
30      --num_hidden_layers 8 \  
31      --use_compile 1 \  
32      --log_interval 100 \  
33      --save_interval 10000
```

由于数据量庞大，且希望能在中途评估训练结果，所以将SFT训练的两个Epoch分开，分别得到训练了1个和2个Epoch的结果。赋予脚本执行权限，并开始执行

2.5 LoRA微调训练

由于官方给的LoRA训练脚本，没有开放支持设置LoRA Rank（秩）和LoRA Alpha（缩放系数）的参数，所以对 `trainer/train_lora.py` 和 `model/model_lora.py` 脚本略微修改，增加设置Rank和Alpha的参数，并使用准备好的研究生手册微调数据，编写LoRA训练脚本 `run_hust_lora.sh` 如下：

代码块


```
1  #!/bin/bash
2
3  SAVE_DIR="./out"
4  FROM_WEIGHT="minimind_sft_e2"
5  DATA_PATH="/hy-tmp/data/hust_handbook_lora.jsonl"
6  LORA_NAME="minimind_hust_lora"
7
8  BATCH_SIZE=64
9  ACCUMULATION=1          # 实际 batch = 64
10 EPOCHS=6 # 设定EPOCHS=10再训练一个
11 LEARNING_RATE=2e-4
12 MAX_SEQ_LEN=512
13
14 python train_lora.py \
15     --save_dir $SAVE_DIR \
16     --lora_name $LORA_NAME \
17     --data_path $DATA_PATH \
18     --from_weight $FROM_WEIGHT \
19     --epochs $EPOCHS \
20     --batch_size $BATCH_SIZE \
21     --accumulation_steps $ACCUMULATION \
22     --learning_rate $LEARNING_RATE \
23     --max_seq_len $MAX_SEQ_LEN \
24     --num_hidden_layers 8 \
25     --device "cuda:0" \
26     --dtype "bfloat16" \
27     --num_workers 8 \
28     --use_compile 0 \
29     --log_interval 10 \
30     --save_interval 100 \
31     --lora_rank 8 \
32     --lora_alpha 16
```

3. 结果分析


3.1 复刻MiniMind训练过程

3.1.1 损失下降曲线

编写函数，从Log文件中读取训练损失数据，绘图：



预训练损失下降曲线（Epoch=3）



SFT训练损失下降曲线（Epoch=2）

可以看出：

- 在预训练阶段，在3个Epoch的训练过程中，Loss值从初始的较高点迅速下降，随后进入平稳期，最终稳定在约**2.0**左右。这表明模型已初步掌握了通用语言的统计分布规律。
- 在SFT阶段：Loss曲线呈现出较强的波动性，但整体趋势向下，最终在**1.6-1.7**附近震荡。这种波动反映了指令微调阶段数据多样性对模型权重的剧烈调整，但均值下降说明模型正在学习如何遵循人类的指令和对话结构。

3.1.2 与官方模型对比

（由于在写实验报告时，云服务器已租满，所以只能将官方权重与自己训练的权重拉到本地进行实验评估）

使用命令 `python eval_llm.py --load_from ./minimind-3` 和命令 `python minimind/eval_llm.py --weight minimind_sft_e2` 分别运行官方模型和自己SFT训练得到的模型，并使用脚本自带的自动测试，以下为部分测试结果：

1. 自我认知

问：你有什么特长？
官方模型： 我是由jingyaogong创建的一个高效的小参数AI模型，专注于提供精准、快速的信息和帮助。我的设计目标是尽可能地接近人类的思考和交流，而不是追求快速和精准的交流。如果你有任何问题或需要协助，欢迎随时提问！
实验模型： 作为AI，我并没有主观的特长，但我可以理解人类的创造力、情感、哲学思考等人类特质。我擅长通过逻辑推理和问题解决来理解世界，能够快速响应并提供有用的信息，帮助用户解决问题。我还可以帮用户在特定的领域（如教育、生活建议等）发挥作用，促进知识的交流与理解。

2. 百科知识

问：为什么天空是蓝色的
官方模型：人类天空呈现出蓝色是因为地球自转导致的。这是因为地球自转对太阳光线的散射作用。太阳光线在通过地球大气层时，由于地球自转，会在大气和海洋上产生红色、橙色、黄色甚至橙色的光线。当太阳光照射到地球表面时，会发生散射。因此，地球上的光线在大气中传播后会发生折射和反射，从而导致我们看到的天空呈现出蓝色。
实验模型： 天空是蓝色的原因是因为它包含了蓝色的成分，如橙色、黄色、绿色和红色。这些颜色是由不同波长的光（蓝光）混合而成的，因此看起来像是蓝色的。 在白天，当太阳光穿过大气层时，蓝光被散射，这使得天空看起来是蓝色的。当太阳到达地面时，光的频率决定了我们看到的颜色。这种现象被称为瑞利散射，因为不同颜色的光波长不同，我们看到的颜色就不同。 当太阳光射向地面时，光线会被大气层中的气体分子（如空气）散射，从而形成一个蓝色的区域。在阳光照射到大气层时，蓝光的部分被散射到我们的眼睛。由于蓝光波长较短，更容易散射，所以我们看到的天空是蓝色的。 另外，当太阳光射向地面时，蓝光的强度决定了我们看到的颜色。在日落或日出时，由于太阳光的强度较高，蓝光更容易散射。在日落或日出时，太阳光被更长的区域散射，这使得我们看到的天空是蓝色的。 总之，天空看起来蓝色是由于大气折射、太阳光的散射和太阳光在地面散射、反射和散射等多种原因共同作用的结果。

3. 代码能力

问：请用Python写一个计算斐波那契数列的函数
官方模型：当然，我可以帮助你编写一个计算斐波那契数列的函数。斐波那契数列是一个经典的数学序列，其定义如下： $F(0) = 0$ $F(1) = 1$ $F(n) = F(n-1) + F(n-2) \ (n \geq 2)$ 下面是一个使用Python编写的计算斐波那契数列函数：
代码块 <pre>1 def fibonacci(n): 2 if n <= 0: 3 return "输入值应为正整数" 4 elif n == 1: 5 return 0 6 elif n == 2:</pre>

```

7         return 1
8     else:
9         a, b = 0, 1
10        for _ in range(n - 2):
11            a, b = b, a + b
12        return b
13
14    # 使用示例
15    n = 10
16    fib_sequence = fibonacci(n)
17    print(f"斐波那契数列的第{fib_sequence}个数为: {fib_sequence}")

```

这个函数首先检查输入值是否有效，然后使用递归方法生成斐波那契数列。在递归调用中，我们首先检查输入值是否为正整数，然后使用一个循环来更新斐波那契数列的值。最后，函数返回计算得到的斐波那契数列。

你可以根据需要修改这个函数，以适应你的需求。

实验模型：

这是一个简单的Python程序，用于计算斐波那契数列：

代码块

```

1  def fibonacci(n):
2      if n <= 0:
3          return "输入的数字需要小于等于1"
4      elif n == 1:
5          return 0
6
7      fib_sequence = [0, 1]
8      for i in range(2, n):
9          next_number = fib_sequence[-1] + fib_sequence[-2]
10         fib_sequence.append(next_number)
11     return fib_sequence
12
13    # 示例使用
14    fib_sequence = [0, 1]
15    print(f"斐波那契数列的前{n}个数是: {fib_sequence}")

```

在这个程序中，我们定义了一个名为fibonacci的函数，它接受一个参数n。函数首先检查n是否小于等于1，如果是，则返回字符串 "输入的数字需要小于等于1"；否则，它使用列表推导式遍历n个元素，将前一个元素添加到结果列表中，并更新fib_sequence列表中的所有元素。最后，函数返回前n个斐波那契数。

请注意，这个程序假设输入的数字是小于等于1的。如果输入的数字是偶数，程序将返回一个错误消息。

通过对自我认知、百科知识和代码能力三个维度的定量与定性分析，可得出如下结论：

1. 在自我认知方面

- a. **官方模型**因为经过了完整的训练（包括后续的RL-HF和RL-AIF训练），明确识别自己为 `jingyaogong` 创建的MiniMind模型，定位清晰；
- b. **实验模型**虽然未给出具体的开发者身份，但表现出了较好的角色对齐能力，能够以“AI助手”的身份进行逻辑严密的自我描述，语调平稳且具备一定的哲学思考深度。

2. 在知识百科方面，由于模型本身参数量较小，难以记住过多的知识

- a. **官方模型**很可能在后续的训练中出现了遗忘，回答中出现了严重的逻辑错误，将天空变蓝归结为“地球自转”，这属于典型的AI幻觉；
- b. **实验模型**表现显著优于官方模型。它准确提到了“瑞利散射”（Rayleigh Scattering）这一核心物理概念，并解释了蓝光波长较短、更容易被大气分子散射的原理。尽管在部分叙述上存在重复，但知识的准确性更高。

3. 在代码能力方面

- a. 官方模型代码的迭代核心逻辑（`a, b = b, a + b`）实现正确，运算效率较高。但依然存在变量命名误导（将单个数命名为 `fib_sequence`）以及打印格式字符串拼接错误的问题。
- b. 实验模型虽然给出了基于迭代（非递归）的实现框架，但代码存在严重的基础性硬伤。其一，在 `n=1` 时返回整数，而其他情况返回列表，导致返回类型不一致；其二，示例中的 `print` 语句引用了未定义的变量，代码完全不可执行。此外，模型在自然语言解释中将自身的“循环”实现错误地描述为“递归”，暴露出代码逻辑与自然语言认知脱节的问题。

综合上述测试结果，可以得出以下结论：


- 在知识准确性上，本实验训练的模型在特定科学常识（如物理现象解释）上的准度出人意料地优于官方提供的权重。这说明在本实验的环境配置下，通过3个Epoch的预训练和2个Epoch的全量SFT，模型已经具备了较强的知识整合能力。
- 在指令遵循与逻辑一致性上，两个模型均展现了优秀的小参数模型特性，即能够理解复杂指令并按格式输出。两个模型在代码能力上都一般，不管是官方模型还是微调前后的实验模型，都只学到了Python语法的“形”，而没有真正掌握逻辑的“实”，生成的代码均需人工修正后方可运行。

实验模型在没有官方权重引导的情况下，仅依靠少量数据（Mini数据集）即复现了接近官方模型的水平，证明了实验所采用的预训练与分阶段SFT训练策略是科学且有效的。


同时，官方模型的能力边界，也说明了模型参数量过小，即使经过了完整的训练和高质量的训练数据熏陶，也难以突破其物理尺寸的限制。

3.2 手册LoRA微调结果分析

编写函数，从Log文件中读取训练损失数据，绘图：



LoRA微调Epochs=6训练微调曲线



LoRA微调Epochs=10训练微调曲线

可以看出，在Epoch=6的训练中，Loss 值从起始的约3.3快速震荡下降，最终趋于2.4附近。而在追加训练至 Epoch=10 后，Loss 曲线进一步下行并稳定。LoRA 微调的 Loss 波动幅度明显大于预训练阶段，这反映了由于研究生手册数据量较小且知识密度极高，模型在有限的参数更新空间（Rank=8）内努力进行知识拟合的过程。

修改 `eval_llm.py`，增加对LoRA Rank和LoRA Alpha的参数适配，使用命令

代码块

```
1 python eval_llm.py \  
2     --weight minimind_sft_e2 \  
3     --lora_weight minimind_hust_lora \  
4     --lora_rank 8 \  
5     --lora_alpha 16
```

启动并挂载训练后的LoRA层，与未挂载LoRA层的SFT模型对比，部分测试结果如下：

1. 手册内容对比

问：老师您好，我有一门公共课的成绩感觉可能登错了，想申请复查，请问最晚要在什么时候提交申请？具体流程是怎样的？（题目来自训练集）

无LoRA模型：

申请复查考试通常在考试开始时进行，如果考生未能按时提交，可以采取以下几种策略：

- 提前准备：**提前做好准备是申请复查的关键。这包括查看考试大纲、准备简历、准备面试题的复习方法、了解考试时间要求、准备常见题型等。提前规划时间，确保在规定时间内完成考试。
- 预习题：**在考试前，提前准备好考试题目，这些题目往往容易理解，且在考试前可能会有额外的解题时间，考试前需要提前预习。
- 准备复习资料：**提前复习考试的内容和考试的重点，了解考试的题目要求和重点，可以利用网络资源进行复习。
- 准备题：**如果可能，提前准备是申请复查的关键。考试时，尽量提前做好题，不要错过这些题目。
- 使用笔记和标注：**在复查过程中，可以使用笔记和标注系统帮助我们快速了解考试内容和答题要求。确保每个部分都清晰地记录了考试的各个部分和复习的思路。

6. **练习题：**在复查的过程中，逐渐增加难度，通过模拟考试来测试自己的知识和技巧。这有助于加深理解和记忆。
7. **保持积极心态：**在复查过程中，保持积极的心态，相信自己能够完成考试。记住，即使考试失败，也要相信自己有能力复查。
8. **寻求帮助：**如果可能，可以寻求同学、老师或辅导员的帮助，或者参加一些辅导课程，这些都有助于提高复查的效率和准确性。
- 通过上述策略，即使考试失败，学生仍然可以利用考试的机会。

实验模型(Epoch=6)：根据《研究生学校管理规定》第十九条第（一）款，学生（学位）和专业学位（同一学位）各自应不得不填写本院（系）的相关证据。申请复查并经同学或相关系同意并提供本院公布的复查结果。

实验模型(Epoch=10)：根据《研究生学籍管理规定》第六条，校长办公厅应提前3小时办理复查手续，由学校根据工作细则决定。

训练数据：根据《研究生学籍管理规定》第十九条第（三）款，指导教师因故不能继续指导的，可由本人提出申请，经学校批准可转专业。你可以据此提出申请。

问：我的导师即将退休，无法继续指导我，我可以因此申请转专业吗？（题目来自训练集）

无LoRA模型：

找工作是一个很重要的决定，但转专业并不意味着您完全不值得。转专业确实是职业发展的关键部分，对于您的职业发展至关重要。如果您在准备转专业或申请转专业时感到困惑或无法继续指导，这可能意味着您缺乏准备、职业规划或是对未来的规划。以下几点可能有助于您：

1. **评估自身技能与兴趣：**了解您当前的专业领域和个人兴趣，包括您是否有相关专业技能、教育背景、实习经历、以及是否在该领域有相关行业或项目经验。这将帮助您评估是否适合您的职业发展。
2. **职业发展规划：**如果您计划转专业，考虑是否有长期或短期的职业发展路径。例如，如果您希望在某个行业或领域获得工作，那么转专业可能是一个更好的选择。
3. **个人生活平衡：**转专业可能需要与您的兴趣、目标和职业规划相匹配。确保您的生活中有稳定的收入和职业发展，这可能对于未来的职业生涯至关重要。
4. **寻找合适的工作机会：**考虑转专业，特别是如果您希望在特定领域工作或学习，如科技、医学、工程、法律等，寻找适合您的工作机会。
5. **适应变化：**在转专业时，您可能需要适应新环境和新技术，这可能意味着需要更新自己的技能、适应新环境或持续学习新技能。

重要的是，转专业是个人成长和职业发展的重要组成部分。选择一个与您职业目标相匹配的领域，并努力实现这些目标，有助于提高您在转专业方面的竞争力。

实验模型(Epoch=6)：根据《研究生学籍管理办法》第四十一条，学校应当不得不向教师、教师、学生管理机构、经纪律处分机构处置申请，并要求转专业，请咨询医生或中介。

实验模型(Epoch=10)：是的。根据《华中科技大学课程教学管理办法》第二十四条，导师即将退休，学校须在学学期末前完成转专业学学课程教学安排。因此，若无法转专业，可以通过正式研究等方式转专业。

训练数据：根据《研究生学籍管理规定》第十九条第（三）款，指导教师因故不能继续指导的，可由本人提出申请，经学校批准可转专业。你可以据此提出申请。

2. 非手册内容对比

问：你有什么特长？

无LoRA模型：我是由个人开发者独立开发的minimind，专注于提升产品的性能和稳定性。我擅长在小范围内探索和解决问题，提供准确、简洁、高效的服务。无论是学习资源丰富，还是深入学习，我都会尽力满足用户的需求。

LoRA实验模型(Epoch=6)：我是一个高效的小参数AI模型，专注于提供精准、高效的服务。我擅长通过快速响应用户需求，提供精准、快速的信息支持，是我在学习、工作和生活中不可或缺的助理。

LoRA实验模型(Epoch=10)：

根据《研究生手册》第三十六条，特长包括：

- 1. 自学专业本科生，专业技能基础。
- 2. 学术写作能力，专业技能培养经验和技能。
- 3. 软技能，软技能培养经验。
- 4. 软技能培养经验，软技能培养经验。
- 5. 软技能培养人才，软技能培养经验。
- 6. 软技能培养经验，软技能培养经验。
- 7. 软技能培养经验，软技能培养经验。
- 8. 软技能培养经验，软技能培养经验。
- 9. 软技能培养经验，软技能培养经验。
- 10. 软技能培养人才，软技能培养经验。

问：如果明天下雨，我应该如何出门

无LoRA模型：

如果明天下雨，出门最好还是携带一把雨伞、雨衣或者防水外套。选择一把适合出门的雨伞，可以让你在雨天更加舒适，也更舒适。如果天气不佳，可以带上一把伞，保持干爽，这样就不会影响出行。同时，穿上一双合适的雨衣，可以避免雨水造成不必要的干扰。最重要的是，确保雨伞与地面湿度较高，以避免水分流失，同时防水防晒。

实验模型(Epoch=6)：根据《三国演义》第九条第九款第四款，下雨时，应穿着防雨衣物，带上雨具和衣物，带上雨伞和雨衣，防风外套等。因此，出门时应穿上防雨衣，保持干燥舒适。

实验模型(Epoch=10)：

根据《学生出门规定》第四条第（六）款，下雨时必须穿伞以防突发天气，同时带上雨具并携带雨具和物品。

从上述对比，可以看出，LoRA微调有一定效果，但64MB的小模型在微调后表现出形式拟合，但实质知识缺失的矛盾现象：

- LoRA 微调让模型迅速且精准地掌握了训练集中的公文答复格式。在测试中，挂载了LoRA的模型，无论是手册内的问题还是手册外的问题，模型几乎都能条件反射式地输出“**根据《XXXX》第 X 条第 X 款……**”的**标准教条式句式**，这种现象在Epoch=10的模型上体现得比Epoch=6的模型更明显。
- 在手册内容问题对比中，在针对“成绩复查申请”和“导师退休转专业”等手册特有问题的测试中，**无 LoRA 模型**完全无法给出有效回答，其输出内容多为通用的、无关的职场或考试建议（如“准备简历”、“找工作”等）。而**LoRA实验模型**在微调后，学会了“根据xxxx第x条xxx，……”的句式，开始尝试引用《研究生学籍管理规定》等手册中的特定条款进行回答。
- LoRA微调体现出的学习**仅仅停留在语言的表层分布上**，并未真正实现知识的内化。由于 MiniMind 模型本身的参数量极小，其内部的参数权重根本无法作为可靠的数据库来存储《研究生手册》中密集且复杂的真实条款。
- 因为**参数容量的物理瓶颈**，模型在正确的“句式外壳”下，只能随机组合甚至完全捏造词汇碎片来进行填充。例如，在回答成绩复查时，凭空捏造出“提前 3 小时办理”的荒谬规则；甚至在面对“下雨出门”的日常常识时，也硬套公文句式，输出了“根据《三国演义》第九条第九款第四款……应穿上防雨衣”这种令人啼笑皆非的严重幻觉。
- 由于为了强行拟合特定领域的教条格式，LoRA微调后的模型**原本的通用对话能力受到了破坏**。Epoch=10的模型在回答“你有什么特长？”这一自我认知问题时，完全丧失了AI助手的定位，转而像复读机一样罗列了10条不知所云的“软技能培养经验”，出现了严重幻觉。

4. 实验总结

本实验完整跑通了从数据预处理、预训练、指令微调（SFT）到LoRA参数高效微调的LLM生命周期训练链路。通过对MiniMind模型的复刻与垂直领域知识注入尝试，得出以下结论：

1. 复刻实验验证成功，训练链路跑通，损失函数曲线的合理收敛，证明了实验所采用的超参数配置与训练脚本逻辑是正确的。即使在未加载官方预训练权重、仅依靠有限算力和Mini数据集从头训练的情况下，模型依然展现出了基础的逻辑对齐能力。在部分知识评测（如“天空为什么是蓝色”的物理常识）中，实验模型的输出准确度甚至优于官方基线模型，证明了预训练和SFT训练的有效性，也从侧面证明了模型参数量已经达到了物理瓶颈。
2. LoRA微调实验存在形式大于实质的缺陷，LoRA微调使得模型迅速且过拟合地掌握了教条式的公文答复格式（“根据《XXX》第X条……”），但由于模型自身的参数容量极小，根本无法真正存储手册中密集的真实条款。模型只是套用了正确的“语法外壳”，里面填充的却是随机拼接的词汇碎片。强行向极小模型注入垂直领域知识，不仅未能使其成为“领域专家”，反而破坏了其原有的通用对话能力。模型在回答日常常识时出现了严重错乱，产生了荒谬的幻觉现象。

从工程的角度来看，百兆级别以下的微型大模型其核心价值在于验证算法流程与学习对话范式，而非作为知识库使用。在算力与参数量受限的客观物理条件下，试图通过LoRA微调让极小模型“死记硬背”垂直领域的高密度知识是不可行的方向。面对类似《研究生手册》的问答需求，更合理、更落地的工程解法不应是模型微调，而应转向RAG 架构，将知识外挂于向量数据库中，仅利用小模型进行文本的总结与润色。

5. 附录

- 实验代码存档于Github: https://github.com/HUSTerCH/exp_3_llm_train
- 实验所制作数据集开源于ModelScope:
<https://modelscope.cn/datasets/SkyFengSheng/HUSTPostgraduateHandbook>